

MATH6207H-hw3

黄伟 123071910077

日期: 2023 年 11 月 1 日上课提交

Question 0.1. Let $\mathbf{A} = (a_{ij})_{n \times n} \in \mathbb{R}^{n \times n}$ be a real square matrix. Recall that the ℓ_1 -norm of a vector $\mathbf{x} \in \mathbb{R}^n$ is given by $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$. Show that the induced ℓ_1 -norm of the matrix \mathbf{A}

$$\|\mathbf{A}\|_1 = \max_{\mathbf{0} \neq \mathbf{x} \in \mathbb{R}^n} \frac{\|\mathbf{Ax}\|_1}{\|\mathbf{x}\|_1}, \quad (1)$$

can be computed by

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|. \quad (2)$$

证明. 首先说明式 (2) 给出的 $\|\mathbf{A}\|_1$ 对 $\forall \mathbf{x} \in \mathbb{R}^n$ 都有 $\|\mathbf{Ax}\|_1 \leq \|\mathbf{A}\|_1 \|\mathbf{x}\|_1$.

$$\begin{aligned} \|\mathbf{Ax}\|_1 &= \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{i=1}^n \sum_{j=1}^n |a_{ij}| |x_j| = \sum_{j=1}^n |x_j| \left(\sum_{i=1}^n |a_{ij}| \right) \\ &\leq \sum_{j=1}^n |x_j| \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \cdot \sum_{j=1}^n |x_j| \\ &= \|\mathbf{A}\|_1 \|\mathbf{x}\|_1, \end{aligned}$$

接下来说明对 $\forall \mathbf{A} \in \mathbb{R}^{n \times n}$, 等号都可以取到. 不妨设 \mathbf{A} 的列绝对值之和最大的列为第 j' 列, 令 \mathbf{x} 为第 j' 元为 1 其它均为 0 的向量, 那么有

$$\|\mathbf{x}\|_1 = 1, \quad \|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| = \sum_{i=1}^n |a_{ij'}|,$$

同时

$$\|\mathbf{Ax}\|_1 = \sum_{i=1}^n \left| \sum_{j=1}^n a_{ij} x_j \right| = \sum_{i=1}^n |a_{ij'}| = \|\mathbf{A}\|_1 \|\mathbf{x}\|_1,$$

综上可知命题成立. □

Question 0.2. (a) Let $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$. Show the equivalence between vector norms and operator norms,

i.e.,

$$\|\mathbf{x}\|_1 = \sup_{\mathbf{y} \neq 0} \frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|_\infty}, \quad \|\mathbf{x}\|_\infty = \sup_{\mathbf{y} \neq 0} \frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|_1}, \quad (3)$$

where (\cdot, \cdot) is the inner product of vectors.

(b) Let \mathbf{A} be a real matrix. Show that $\|\mathbf{A}\|_1 = \|\mathbf{A}^T\|_\infty$.

证明. (a) 先说明 $\frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|_\infty} \leq \|\mathbf{x}\|_1$, $\frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|_1} \leq \|\mathbf{x}\|_\infty$. 直接验证

$$\frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|_\infty} = \sum_{i=1}^n x_i \cdot \frac{y_i}{\|\mathbf{y}\|} \leq \sum_{i=1}^n |x_i| = \|\mathbf{x}\|_1, \quad (4)$$

$$\frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|_1} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n |y_i|} \leqslant \frac{\|\mathbf{x}\|_\infty \sum_{i=1}^n |y_i|}{\sum_{i=1}^n |y_i|} = \|\mathbf{x}\|_\infty, \quad (5)$$

前者取 $y_i = \text{sgn}(x_i)$ 可以取到等号, 后者 \mathbf{y} 第 i' 元为 $\text{sgn}(x'_{i'})$ 其余为 0 取到等号, 其中 i' 为 \mathbf{x} 最大元所在位置. 综上可知命题成立.

(b) 根据定义

$$\begin{aligned} \|\mathbf{A}\|_1 &= \sup_{\mathbf{x} \neq 0} \frac{\|\mathbf{Ax}\|_1}{\|\mathbf{x}\|_1} = \sup_{\mathbf{x} \neq 0} \frac{1}{\|\mathbf{x}\|_1} \sup_{\mathbf{y} \neq 0} \frac{(\mathbf{Ax}, \mathbf{y})}{\|\mathbf{y}\|_\infty} \\ &= \sup_{\mathbf{y} \neq 0} \frac{1}{\|\mathbf{y}\|_\infty} \sup_{\mathbf{x} \neq 0} \frac{(\mathbf{Ax}, \mathbf{y})}{\|\mathbf{x}\|_1} \\ &= \sup_{\mathbf{y} \neq 0} \frac{1}{\|\mathbf{y}\|_\infty} \sup_{\mathbf{x} \neq 0} \frac{(\mathbf{A}^T \mathbf{y}, \mathbf{x})}{\|\mathbf{x}\|_1} \\ &= \sup_{\mathbf{y} \neq 0} \frac{\|\mathbf{A}^T \mathbf{y}\|_\infty}{\|\mathbf{y}\|_\infty} = \|\mathbf{A}^T\|_\infty, \end{aligned}$$

即证. \square

Question 0.3. Let \mathbf{A} be a symmetric positive definite matrix. Given the maximal and minimal eigenvalues of \mathbf{A} , find the optimal parameter for the Richardson iteration method.

可以证明最佳参数为 $\frac{2}{\lambda_{\min} + \lambda_{\max}}$.

证明. 设求解的方程为 $\mathbf{Ax} = \mathbf{b}$, 根据定义 Richardson 迭代为

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha(\mathbf{b} - \mathbf{Ax}_k) = (\mathbf{E} - \alpha\mathbf{A})\mathbf{x}_k + \alpha\mathbf{b}, \quad (6)$$

要使得参数最优, 只要令 $\rho(\mathbf{E} - \alpha\mathbf{A})$ 最小, 只要令 $\max_{\lambda} \{|1 - \alpha\lambda|\}$ 最小. 可以知道在 $1 - \alpha\lambda_{\min} + 1 - \alpha\lambda_{\max} = 0$ 时取到最小值, 所以最优参数为 $\frac{2}{\lambda_{\min} + \lambda_{\max}}$. \square

Question 0.4. Prove the following theorems:

- (a) Suppose \mathbf{A} is a symmetric matrix with positive diagonal elements. If it is strictly diagonally dominant, or irreducible diagonally dominant, then \mathbf{A} is positive definite.
- (b) If $\mathbf{A} = (a_{i,j})_{n \times n} \in \mathbb{R}^{n \times n}$ is symmetric and positive definite with $a_{i,j} \leq 0, \forall i \neq j$, then the Jacobi method is convergent.

定义 0.1 (不可约). 如果存在 n 阶排列矩阵 \mathbf{P} , 使 $\mathbf{P}^T \mathbf{AP}$ 有如下结果

$$\mathbf{P}^T \mathbf{AP} = \begin{pmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ 0 & \mathbf{A}_{22} \end{pmatrix}, \quad (7)$$

其中 $\mathbf{A}_{11}, \mathbf{A}_{22}$ 为方阵. 则称 \mathbf{A} 为可约矩阵, 若不存在则为不可约矩阵.

证明. (a) 严格主对角占优: 设 $\mathbf{A} = (a_{i,j})_{n \times n} \in \mathbb{R}^{n \times n}$ 是严格主对角占优的对称矩阵, 且对角线元素为正, 根据定义有

$$a_{i,i} > \sum_{j \neq i} |a_{i,j}|, \quad \forall i \in \{1, 2, \dots, n\}, \quad (8)$$

因为实对称, 所以 \mathbf{A} 的特征值都是实数, 任取 \mathbf{A} 的特征值 $\lambda \in \mathbb{R}$, 对应特征向量为 $\mathbf{x} = (x_1, \dots, x_n)^T$, 从而 $\mathbf{Ax} = \lambda\mathbf{x}$, 即

$$\sum_{j=1}^n a_{i,j} x_j = \lambda x_i, \quad \forall i \in \{1, 2, \dots, n\}, \quad (9)$$

设 $|x_{i'}| = \max |x_i|$, 即第 i' 元绝对值最大, 那么

$$(a_{i',i'} - \lambda)x_{i'} = -\sum_{j \neq i'} a_{i',j}x_j, \quad (10)$$

那么

$$\begin{aligned} (a_{i',i'} - \lambda)|x_{i'}| &= |(a_{i',i'} - \lambda)x_{i'}| = \left| \sum_{j \neq i'} a_{i',j}x_j \right| \\ &\leq \sum_{j \neq i'} |a_{i',j}x_j| \leq \sum_{j \neq i'} |a_{i',j}| |x_j| \leq \sum_{j \neq i'} |a_{i',j}| |x_{i'}| \\ &= |x_{i'}| \sum_{j \neq i'} |a_{i',j}| < |x_{i'}| \cdot a_{i',i'}, \end{aligned}$$

从而 $\lambda|x_{i'}| > 0$, $\lambda > 0$. 因为 λ 的选取是任意的, 所以 \mathbf{A} 的特征值均是正数, 所以 \mathbf{A} 正定.

不可约对角占优: 设 $\mathbf{A} = (a_{i,j})_{n \times n} \in \mathbb{R}^{n \times n}$ 是不可约主对角占优的对称矩阵, 且对角线元素为正. 根据前面的证明, 修改式 (8) 中的严格不等号为大于等于号, 类似的, 可以说明对角占优矩阵的特征值非负, 从而只要证明不可约的条件下不存在 0 特征值, 只要证 $\mathbf{Ax} = 0$ 没有非零解. 采用反证法, 假设 $\mathbf{Ax} = 0$ 存在非零解, 设为 $\mathbf{x} = (x_1, \dots, x_n)^T$, 首先说明不可能 $|x_1| = \dots = |x_n|$, 如果成立, 那么会有对 $\forall i$ 都有

$$|a_{ii}| |x_i| = |a_{ii}x_i| = \left| \sum_{j \neq i} a_{ij}x_j \right| \leq \sum_{j \neq i} |a_{ij}| |x_j| = |x_i| \sum_{j \neq i} |a_{ij}| \leq |a_{ii}| |x_i|, \quad (11)$$

那么等号全部成立, 即对 $\forall i$ 都有 $|a_{ii}| = \sum_{j \neq i} |a_{ij}|$, 这与 \mathbf{A} 为对角占优矩阵矛盾, 所以假设不成立.

接下来其中绝对值最大元下标构成的集合为 I , 即

$$I = \{i \mid |x_i| = \|\mathbf{x}\|_\infty\}, \quad (12)$$

显然 I 非空, 因为 $|x_i|$ 不会全部相同, 所以 $\{1, 2, \dots, n\} \setminus I$ 也非空. $\forall i \in I$, 有

$$|a_{ii}| \cdot |x_i| = |a_{ii}x_i| = \left| \sum_{j \neq i} a_{ij}x_j \right| \leq \sum_{j \neq i} |a_{ij}| |x_j|, \quad (13)$$

于是

$$\sum_{j \neq i} |a_{ij}| \leq |a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \cdot \frac{|x_j|}{|x_i|} \leq \sum_{j \neq i} |a_{ij}|, \quad (14)$$

第一个不等号是对角占优, 最后一个不等号是因为 $|x_i|$ 为绝对值最大元, 从而上式取到等号. 对于任意的非绝对值最大元 x_k (或者说 $\forall k \notin I$), 只能 $a_{ik} = 0$. 这里的 $i \in I$ 和 $k \notin I$ 都是任意的, 所以可以取到排列矩阵 \mathbf{P} 使得 $\mathbf{P}^T \mathbf{A} \mathbf{P}$ 成为分块上三角阵, 进而可约, 矛盾. 综上可知不可约对角占优矩阵正定.

(b) 设 $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{L}^T$, 其中 \mathbf{D} 为对角矩阵, \mathbf{L} 为下三角矩阵, 二者元素非负. Jacobi 方法迭代矩阵为

$$\mathbf{B} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{L}^T) = \mathbf{E} - \mathbf{D}^{-1}\mathbf{A}, \quad (15)$$

设 λ, \mathbf{x} 为任意一对特征向量与特征值, 有 $\mathbf{Bx} = \lambda\mathbf{x}$, 那么有

$$(\mathbf{L} + \mathbf{L}^T)\mathbf{x} = \lambda\mathbf{D}\mathbf{x} \Rightarrow (\lambda\mathbf{D} - \mathbf{L} - \mathbf{L}^T)\mathbf{x} = 0, \quad (16)$$

若存在 $\lambda \geq 1$, 因为 $\forall \mathbf{y}$

$$\mathbf{y}^T(\lambda\mathbf{D} - \mathbf{L} - \mathbf{L}^T)\mathbf{y} \geq \mathbf{y}^T(\mathbf{D} - \mathbf{L} - \mathbf{L}^T)\mathbf{y} \geq \mathbf{y}^T\mathbf{Ay} > 0, \quad (17)$$

所以 $\lambda\mathbf{D} - \mathbf{L} - \mathbf{L}^T$ 正定, 不存在非零齐次解, 所以 $\lambda < 1$ 恒成立. 从而 $\rho(\mathbf{B}) < 1$, Jacobi 方法收敛.¹ \square

Question 0.5. The symmetric Gauss-Seidel method is obtained by combining an iteration of Gauss-Seidel method with an iteration of backward Gauss-Seidel method. Precisely, the k -th iteration of the symmetric Gauss-Seidel method for solving $\mathbf{Ax} = \mathbf{b}$, with $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$ is

$$\mathbf{x}_{k+1/2} = \mathbf{x}_k + (\mathbf{D} - \mathbf{L})^{-1}(\mathbf{b} - \mathbf{Ax}_k), \quad (18)$$

$$\mathbf{x}_{k+1} = \mathbf{x}_{k+1/2} + (\mathbf{D} - \mathbf{U})^{-1}(\mathbf{b} - \mathbf{Ax}_{k+1/2}), \quad (19)$$

i.e., the iteration method can be written as

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{P}^{-1}(\mathbf{b} - \mathbf{Ax}_k), \quad (20)$$

If \mathbf{A} is a symmetric positive definite matrix:

- (a) Compute the preconditioner \mathbf{P} of the symmetric Gauss-Seidel method, and show that \mathbf{P} is symmetric positive definite.
- (b) Show that the spectral radius of the iteration matrix is less than 1.

证明. (a) 根据题意

$$\begin{aligned} \mathbf{x}_{k+1} &= \mathbf{x}_k + (\mathbf{D} - \mathbf{L})^{-1}(\mathbf{b} - \mathbf{Ax}_k) + (\mathbf{D} - \mathbf{U})^{-1}(\mathbf{b} - \mathbf{A}(\mathbf{x}_k + (\mathbf{D} - \mathbf{L})^{-1}(\mathbf{b} - \mathbf{Ax}_k))) \\ &= \mathbf{x}_k + ((\mathbf{D} - \mathbf{L})^{-1} + (\mathbf{D} - \mathbf{U})^{-1} - (\mathbf{D} - \mathbf{U})^{-1}\mathbf{A}(\mathbf{D} - \mathbf{L})^{-1})(\mathbf{b} - \mathbf{Ax}_k) \\ &= \mathbf{x}_k + ((\mathbf{D} - \mathbf{L})^{-1} + (\mathbf{D} - \mathbf{U})^{-1} - (\mathbf{D} - \mathbf{U})^{-1}((\mathbf{D} - \mathbf{L}) + (\mathbf{D} - \mathbf{U}) - \mathbf{D})(\mathbf{D} - \mathbf{L})^{-1})(\mathbf{b} - \mathbf{Ax}_k) \\ &= \mathbf{x}_k + (\mathbf{D} - \mathbf{U})^{-1}\mathbf{D}(\mathbf{D} - \mathbf{L})^{-1}(\mathbf{b} - \mathbf{Ax}_k), \end{aligned}$$

所以 $\mathbf{P} = (\mathbf{D} - \mathbf{L})\mathbf{D}^{-1}(\mathbf{D} - \mathbf{U})$, 注意到 $\mathbf{L}^T = \mathbf{U}$, $\mathbf{D}^T = \mathbf{D}$, 所以

$$\mathbf{P}^T = (\mathbf{D} - \mathbf{U})^T(\mathbf{D}^{-1})^T(\mathbf{D} - \mathbf{L})^T = (\mathbf{D} - \mathbf{L})\mathbf{D}^{-1}(\mathbf{D} - \mathbf{U}) = \mathbf{P}, \quad (21)$$

所以 \mathbf{P} 对称. 因为 \mathbf{A} 正定, 所以对角元均为正, 所以 \mathbf{D} 正定, 所以 \mathbf{D}^{-1} 正定. 而 \mathbf{D}^{-1} 与 \mathbf{P} 合同, 所以 \mathbf{P} 正定.

(b) 迭代矩阵

$$\mathbf{B} = \mathbf{E} - \mathbf{P}^{-1}\mathbf{A}, \quad (22)$$

设 λ 是 \mathbf{B} 的一个特征值, 对应特征向量 $\mathbf{x} \neq 0$, 那么有

$$\mathbf{Bx} = \lambda\mathbf{x} \Rightarrow (1 - \lambda)\mathbf{Px} = \mathbf{Ax}, \quad (23)$$

与 \mathbf{x} 内积得到

$$1 - \lambda = \frac{\mathbf{x}^T \mathbf{Ax}}{\mathbf{x}^T \mathbf{Px}} > 0, \quad (24)$$

所以 $\lambda < 1$. 另一方面, 有 $\mathbf{P} = \mathbf{A} + \mathbf{LD}^{-1}\mathbf{U}$, 从而

$$(1 - \lambda)\mathbf{LD}^{-1}\mathbf{Ux} = \lambda\mathbf{Ax}, \quad (25)$$

所以

$$\frac{\lambda}{1 - \lambda} = \frac{\mathbf{x}^T \mathbf{LD}^{-1}\mathbf{Ux}}{\mathbf{x}^T \mathbf{Ax}} > 0, \quad (26)$$

¹没用到 $a_{i,j} \leq 0, \forall i \neq j$ 的条件.

所以 $\lambda > 0$. 于是 $0 < \lambda < 1$, 迭代矩阵收敛.

□

Question 0.6. Consider the linear system

$$\frac{1}{h^2} \begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \vdots \\ u_n \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \\ f_3 \\ \vdots \\ f_n \end{bmatrix} \quad (27)$$

where, $h = 1/n$, $f_i = (3x_i + x_i^2)e^{x_i}$ and $x_i = i/n$ for $i = 1, 2, \dots, n$.

(a) Given a real matrix \mathbf{A} , show that

$$\rho(\mathbf{A}) = \lim_{k \rightarrow \infty} \|\mathbf{A}^k\|^{1/k}, \quad (28)$$

where $\rho(\mathbf{A})$ is the spectral radius of \mathbf{A} and $\|\cdot\|$ is any matrix norm.

(b) Define the asymptotic convergence rate of an iteration method as $R_\infty = -\ln \rho(\mathbf{B})$ where \mathbf{B} is the iteration matrix. Let \mathbf{B}_{Jacobi} and \mathbf{B}_{GS} be the iteration matrices of the Jacobi method and the Gauss-Seidel method, respectively. Calculate $\rho(\mathbf{B}_{Jacobi})$, $\rho(\mathbf{B}_{GS})$ and the corresponding asymptotic convergence rates.

(c) Write a computer program to numerically verify the asymptotic convergence rates.

(d) Write a computer program to solve the linear system with the SOR method. For each $n = 1000, 2000, 4000, 8000$, chose different relaxation parameter $\omega_k = 1 + k/101$ for $k = 1, 2, \dots, 100$ to collect the required iteration numbers until convergence. Plot your results with x -axis for ω and y -axis for iteration number. Use double precision in your computation and set the relative residual tolerance as $\varepsilon_{rel} = 1 \times 10^{-8}$.

证明. (a) 根据谱半径定义, 取 $\lambda = \rho(\mathbf{A})$, \mathbf{x} 为 λ 对应特征向量, 同时任取 \mathbf{y} 使得 $\mathbf{x}\mathbf{y}^T$ 的矩阵范数非 0, 那么

$$\rho(\mathbf{A})\|\mathbf{x}\mathbf{y}^T\| = \|\lambda\mathbf{x}\mathbf{y}^T\| = \|\mathbf{A}\mathbf{x}\mathbf{y}^T\| \leq \|\mathbf{A}\|\|\mathbf{x}\mathbf{y}^T\|, \quad (29)$$

所以 $\rho(\mathbf{A}) \leq \|\mathbf{A}\|$, 所以 $\rho(\mathbf{A}) \leq \|\mathbf{A}^k\|^{1/k}$. 另一方面 $\forall \varepsilon > 0$, 定义

$$\mathbf{A}_\varepsilon = [\rho(\mathbf{A}) + \varepsilon]^{-1} \mathbf{A}, \quad (30)$$

显然有 $\rho(\mathbf{A}_\varepsilon) < 1$, 于是 $\lim_{k \rightarrow \infty} \mathbf{A}_\varepsilon^k = 0$, 这会得到 $\|\mathbf{A}_\varepsilon^k\| < 1$, 所以 $\|\mathbf{A}^k\|^{1/k} \leq \rho(\mathbf{A}) + \varepsilon$, 根据任意性得到 $\rho(\mathbf{A}) \geq \|\mathbf{A}^k\|^{1/k}$. 综上 $\rho(\mathbf{A}) = \|\mathbf{A}^k\|^{1/k}$.

(b) 对于 $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$, 有

$$\mathbf{B}_{Jacobi} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}), \quad (31)$$

$$\mathbf{B}_{GS} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}, \quad (32)$$

代入本题得到

$$\mathbf{B}_{Jacobi} = \frac{1}{2} \begin{bmatrix} 1 & & & & \\ 1 & 1 & & & \\ & \ddots & \ddots & & \\ & & 1 & 1 & \\ & & & 1 & \end{bmatrix}, \quad (33)$$

$$\mathbf{B}_{GS} = \begin{bmatrix} 0 & \frac{1}{2} & 0 & \cdots & 0 & 0 \\ 0 & \frac{1}{4} & \frac{1}{2} & \cdots & 0 & 0 \\ 0 & \frac{1}{8} & \frac{1}{4} & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & \frac{1}{2^{n-1}} & \frac{1}{2^{n-2}} & \cdots & \frac{1}{4} & \frac{1}{2} \\ 0 & \frac{1}{2^n} & \frac{1}{2^{n-1}} & \cdots & \frac{1}{8} & \frac{1}{4} \end{bmatrix}, \quad (34)$$

(c) 对 4 阶矩阵迭代结果如下

Jacobi:

```
>>> k= 1, rho= 1.000
>>> k= 2, rho= 0.866
>>> k= 3, rho= 0.855
>>> k= 4, rho= 0.841
>>> k= 5, rho= 0.835
>>> k= 6, rho= 0.831
>>> k= 7, rho= 0.827
>>> k= 8, rho= 0.825
>>> k= 9, rho= 0.823
>>> k=10, rho= 0.822
>>> k=11, rho= 0.821
>>> k=12, rho= 0.820
>>> k=13, rho= 0.819
>>> k=14, rho= 0.818
>>> k=15, rho= 0.818
>>> k=16, rho= 0.817
>>> k=17, rho= 0.817
>>> k=18, rho= 0.816
>>> k=19, rho= 0.816
>>> k=20, rho= 0.815
```

Gauss-Siedel:

```
>>> k= 1, rho= 0.875
>>> k= 2, rho= 0.791
```

```

>>> k= 3, rho= 0.750
>>> k= 4, rho= 0.726
>>> k= 5, rho= 0.711
>>> k= 6, rho= 0.701
>>> k= 7, rho= 0.694
>>> k= 8, rho= 0.689
>>> k= 9, rho= 0.685
>>> k=10, rho= 0.682
>>> k=11, rho= 0.680
>>> k=12, rho= 0.677
>>> k=13, rho= 0.676
>>> k=14, rho= 0.674
>>> k=15, rho= 0.673
>>> k=16, rho= 0.672
>>> k=17, rho= 0.671
>>> k=18, rho= 0.670
>>> k=19, rho= 0.669
>>> k=20, rho= 0.668

```

(d) 根据定义, SOR 法迭代为

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right), \quad (35)$$

于是写出代码为

```

void SOR_METHOD_ITER(int n, double* A, double* b, double* x, double omega){
    double sum;
    int j;
    for(int i=0;i<n;i++){
        sum=0.0;
        for(j=0;j<i;j++){
            sum += A[i*n+j]*x[j];
        }
        for(j=i+1;j<n;j++){
            sum += A[i*n+j]*x[j];
        }
        x[i] = (1-omega)*x[i]+omega*(b[i]-sum)/A[i*n+i];
    }
}

```

□